- CSC5066 : PROJET SPARK

ANALYSE DU CHURN CLIENT AVEC SPARK

ROBERT UNG

JEU DE DONNÉES

- Dataset utilisé : Telco Customer Churn (source Kaggle)

- Données : fichier csv (7043 lignes, 21 colonnes)
- Variable cible : Churn (départ des clients)
- Variables catégorielles : gender, SeniorCitizen, Partner, Dependents, PhoneService, MultipleLines, InternetService, OnlineSecurity...
- Variables numériques : tenure, MonthlyCharges, TotalCharges

OBJECTIF

Comprendre les causes du churn et prédire le départ des clients d’un opérateur télécom

CHAÎNE DE TRAITEMENTS

1 Chargement des données

→ Lecture du CSV avec Spark

2 Nettoyage & préparation

→ Gestion des valeurs manquantes
→ Conversion en formats numériques
→ Nettoyage de "TotalCharges"

3 Encodage & assemblage

→ StringIndexer
→ OneHotEncoder
→ VectorAssembler

4 Rééquilibrage des classes

→ Oversampling (classe churn “Yes”)

```
+-----+-----+
|Churn|count|
+-----+-----+
|   No| 5163|
|  Yes| 1869|
+-----+-----+
```

5 Modélisation MLlib

→ Régression Logistique
→ Random Forest
→ Cross-validation

6 Évaluation & visualisations

→ Accuracy, AUC
→ Matrices de confusion
→ Feature importance

UTILISATION DE SPARK DANS LE PROJET

- Lecture du dataset en DataFrame Spark
- Nettoyage (remplacement valeurs manquantes, conversions)
- Pipeline Spark MLlib :
  - StringIndexer
  - OneHotEncoder
  - VectorAssembler
- Entraînement des modèles MLlib (LogisticRegression, RandomForest)
- Cross-validation avec ParamGridBuilder

RÉSULTATS SANS OVERSAMPLING

- Régression logistique
  - Accuracy: 0.79
  - F1: 0.79
  - Precision: 0.79
  - Recall: 0.79
  - AUC: 0.84

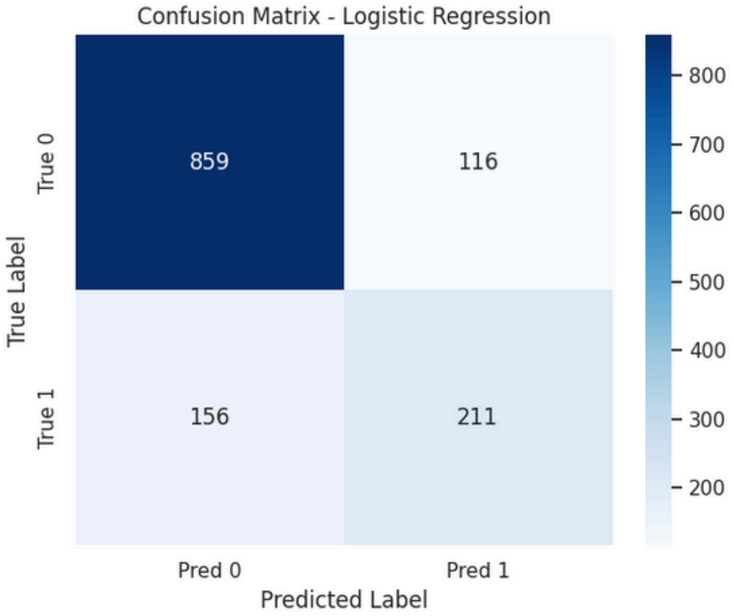

- Random forest
  - Accuracy: 0.79
  - F1: 0.78
  - Precision: 0.78
  - Recall: 0.79
  - AUC: 0.84

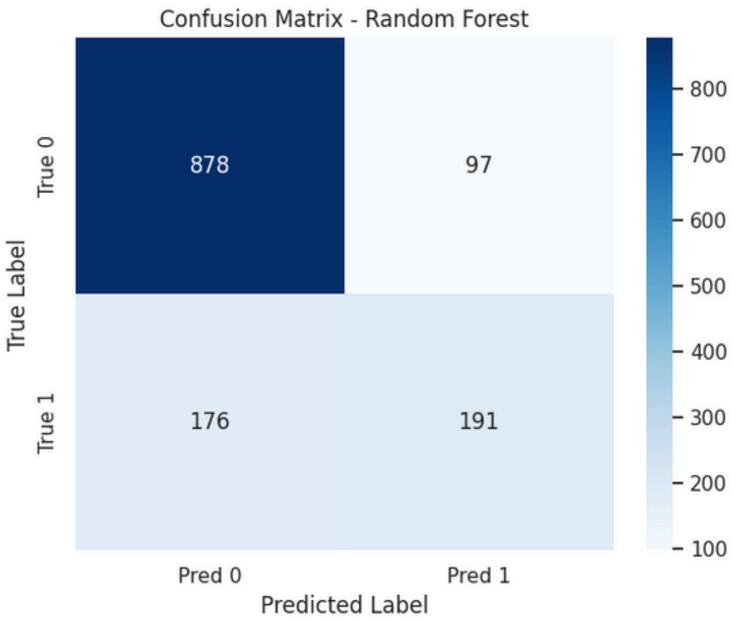

RÉSULTATS APRÈS OVERSAMPLING

- Régression logistique
  - Accuracy: 0.76 ↘
  - F1: 0.76 ↘
  - Precision: 0.79
  - Recall: 0.79
  - AUC: 0.84

- Random forest
  - Accuracy: 0.78 ↘
  - F1: 0.78
  - Precision: 0.82 ↗
  - Recall: 0.79
  - AUC: 0.86 ↗

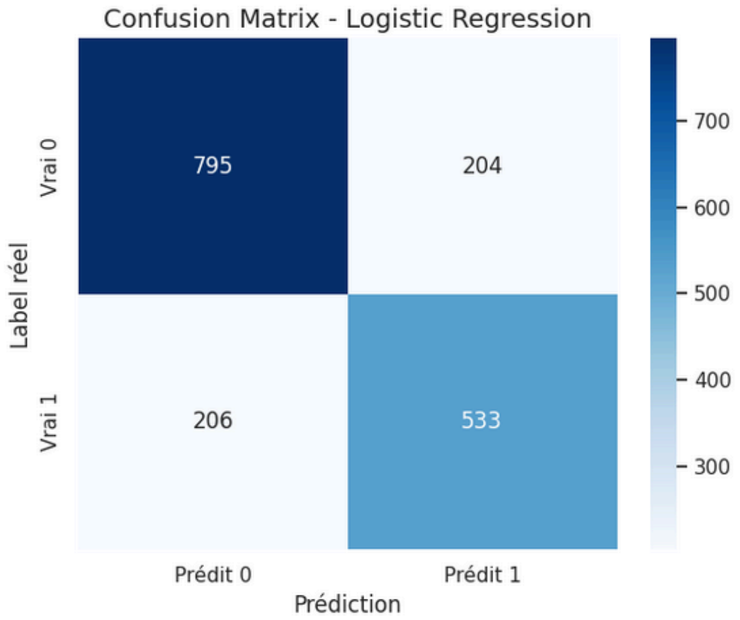

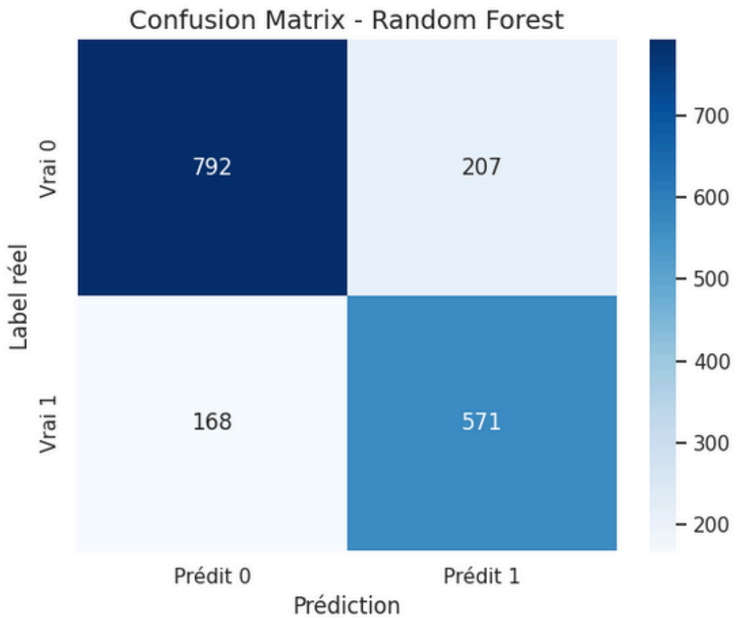

OPTIMISATION AVEC CROSS-VALIDATION

- Utilisation de CrossValidator de Spark MLlib
- Grid Search sur :
  - numTrees (50, 100)
  - maxDepth (5, 7)
- Sélection automatique du meilleur modèle
- Meilleurs paramètres trouvés :
  - numTrees = 100
  - maxDepth = 7
- Amélioration de la stabilité du modèle

CAUSES DU CHURN

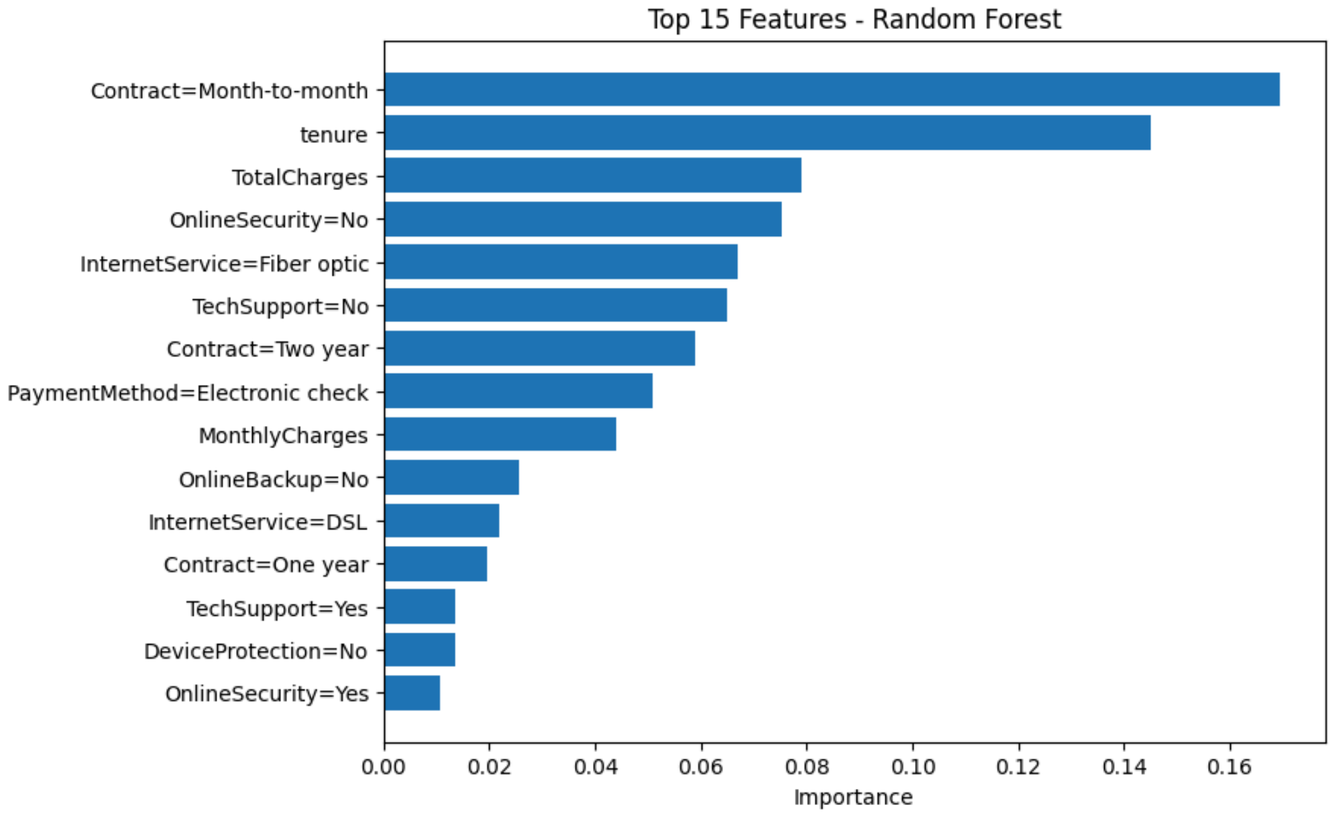

- Le type de contrat (Month-to-month) : les clients mensuels sont plus volatils.
- La durée d’ancienneté (tenure) : plus un client reste longtemps, plus il est fidèle.
- Les services liés à la sécurité et au support : leur absence augmente fortement le risque de départ.

ACCÉLÉRATION GPU AVEC RAPIDS CUML

- Objectif : comparer Spark (CPU) vs RAPIDS (GPU)
- Modèle testé : Random Forest (cuML)
- Données transférées en cuDF (DataFrame GPU)
- Résultats :
  - Accuracy GPU : 0.787
  - AUC GPU : 0.818
  - Temps d’entraînement : 2.57 secondes (contre ~45 sec avec CPU)
- Conclusion : entraînement beaucoup plus rapide grâce au GPU

DÉMONSTRATION

CONCLUSION

- Causes du churn identifiés
- Meilleur modèle : Random Forest avec oversampling, avec un AUC de 0.861
- RAPIDS a montré que les GPU apporte des gains de rapidité considérables